



Université Mohamed V  
École Nationale Supérieure d'Informatique  
Et d'Analyse des Systèmes  
Rabat



Filière : Ingénierie en Data Science and IoT (IDSIT)

## RAPPORT DE PROJET FÉDÉRATEUR S5

---

# Architectures d'apprentissage profond appliquées à la classification du dépistage du cancer du sein

---

Réalisé par :

Fadwa LACHAM

Ghizlane BENNANI

Encadré par :

Pr. Ali IDRI

Jury :

Pr. Ali IDRI

Pr. Widad ELOUATAOUI

Pr. Ibtissam ABNANE

# Remerciements

La présentation de ce modeste travail nous offre l'occasion de remercier en premier lieu notre encadrant, Monsieur **Ali IDRI**, pour son soutien indéfectible tout au long de notre projet. Dès le début, il a su être à notre écoute, prendre en compte nos préoccupations et nos idées, tout en nous offrant des orientations pertinentes et des conseils avisés. Son accompagnement nous a permis d'acquérir une expérience précieuse et enrichissante, contribuant grandement au bon déroulement de ce travail.

Nous tenons également à exprimer notre gratitude aux membres du jury : Madame **Ibtissam ABNANE**, Monsieur **Ali IDRI** et Madame **Widad ELOUATAOUI**, pour l'intérêt qu'ils ont porté à ce projet. Leurs remarques constructives et leurs retours pertinents ont enrichi notre réflexion et ont permis d'améliorer significativement notre travail.

Nous souhaitons adresser un profond respect et un remerciement particulier à l'ensemble du corps professoral de l'École Nationale Supérieure de l'Informatique et de l'Analyse des Systèmes (ENSIAS). Leur engagement et leur dévouement créent un environnement propice à l'apprentissage et au développement, facilitant ainsi le bon déroulement de nos études.

Enfin, nous exprimons notre reconnaissance infinie à nos familles, qui ont toujours été présentes à nos côtés tout au long de ce projet. Leur soutien inconditionnel, tant moral que matériel, a été une source inestimable de motivation et de force.

Que tous ceux et celles qui ont contribué, de près ou de loin, à l'accomplissement de ce travail trouvent ici l'expression de nos remerciements les plus chaleureux.

# Résumé

Le cancer du sein (CS) est l'un des cancers les plus fréquemment diagnostiqués et constitue une des principales causes de mortalité. La mammographie joue un rôle essentiel dans la détection précoce de cette maladie. Ce travail a pour objectif d'évaluer les performances de modèles d'apprentissage profond appliqués à la classification binaire des images de mammographies.

Dans cette étude, nous nous concentrons sur trois architectures de réseaux de neurones convolutifs profonds (CNN), VGG16, VGG19, DenseNet201. L'évaluation a été réalisée à partir de quatre métriques principales : exactitude, précision, rappel et score F1.

Les expériences ont été conduites à partir du jeu de données CBIS-DDSM, comprenant 4000 images. Les résultats obtenus fournissent des indications préliminaires sur l'efficacité des architectures VGG16, VGG19 et DenseNet201 pour la classification des mammographies en deux catégories (positif et négatif).

---

**Mots clés :** cancer du sein, mammographie, apprentissage profond, classification binaire, VGG16, VGG19, DenseNet201

---

# Abstract

Breast cancer (BC) is one of the most frequently diagnosed cancers and remains a leading cause of mortality. Mammography plays a crucial role in the early detection of this disease. This study aims to evaluate the performance of deep learning models applied to the binary classification of mammography images.

We focus on three Convolutional Neural Network (CNN) architectures, VGG16, VGG19, and DenseNet201, and evaluate their performance based on four key metrics : accuracy, precision, recall, and F1-score.

The experiments were conducted using the CBIS-DDSM dataset, which includes 4000 images. The results provide preliminary insights into the effectiveness of the VGG16, VGG19, and DenseNet201 architectures for binary classification of mammograms (positif and negatif).

---

**Keywords :** breast cancer, mammography, deep learning, binary classification, VGG16, VGG19, DenseNet201

---

# Liste des abréviations

<b>CS</b>	<i>Cancer du sein</i>
<b>CNN</b>	<i>Convolutional Neural Network</i>
<b>CBIS-DDSM</b>	<i>Curated Breast Imaging Subset of Digital Database for Screening Mammography</i>
<b>DL</b>	<i>Deep Learning</i>
<b>ML</b>	<i>Machine Learning</i>
<b>VGG16</b>	<i>Visual Geometry Group 16-layer network</i>
<b>VGG19</b>	<i>Visual Geometry Group 19-layer network</i>
<b>DenseNet</b>	<i>Densely Connected Convolutional Networks</i>
<b>FP</b>	<i>Faux Positif</i>
<b>FN</b>	<i>Faux Négatif</i>
<b>CLAHE</b>	<i>Contrast Limited Adaptive Histogram Equalization</i>

# Table des figures

1.1	Architecture du processus de modélisation et d'évaluation des modèles de Deep Learning pour la détection du cancer du sein	5
2.1	Structure du DataSet . . . . .	8
2.2	Colonnes importantes du Dataset . . . . .	9
2.3	Répartition des pathologies dans le Dataset du Mass Train .	10
2.4	Répartition des pathologies dans le Dataset du Mass Test .	10
2.5	un échantillon de mammographies issues du dataset . . . . .	11
3.1	Exemple d'images du DataSet . . . . .	14
3.2	Comparaison des histogrammes avant et après l'application de CLAHE . . . . .	15
3.3	Mappage des étiquettes de pathologie . . . . .	17
3.4	Équilibrage des classes suite à l'undersampling . . . . .	18
3.5	Comparaison des images avant et après prétraitement . . . . .	19
4.1	Architecture de VGG16 adaptée pour le diagnostic du cancer du sein. . . . .	20
4.2	Évolution de la Perte et de la Précision pour le Modèle VGG16	23
4.3	Courbe ROC pour le Modèle VGG16 . . . . .	24
4.4	Architecture de VGG19 adaptée pour le diagnostic du cancer du sein. . . . .	26
4.5	Évolution de la Perte et de la Précision pour le Modèle VGG19	28
4.6	Courbe ROC pour le Modèle VGG19 . . . . .	29
4.7	Architecture de DenseNet. . . . .	32
4.8	Évolution de la Perte et de la Précision pour le Modèle DenseNet205 . . . . .	33
4.9	Courbe ROC pour le Modèle DenseNet205 . . . . .	35
4.10	Tableau de Synthèse des Résultats . . . . .	36
5.1	Visual Studio Code . . . . .	39
5.2	Python . . . . .	40

5.3	Flask . . . . .	40
5.4	HTML et CSS . . . . .	40
5.5	Page d'accueil de l'application : Sensibilisation au cancer du sein. . . . .	42
5.6	Formulaire de soumission d'image . . . . .	42
5.7	Affichage des résultats : Prédiction et Confiance. . . . .	43

# Table des matières

<b>Remerciements</b> . . . . .	<b>I</b>
<b>Résumé</b> . . . . .	<b>II</b>
<b>Abstract</b> . . . . .	<b>III</b>
<b>Introduction générale</b> . . . . .	<b>1</b>
<b>1 Contexte général du projet</b> . . . . .	<b>3</b>
1.1 Introduction . . . . .	3
1.2 Contexte générale . . . . .	3
1.3 Problématique . . . . .	4
1.4 Objectif de l'étude . . . . .	4
1.5 Méthodologie générale . . . . .	5
1.6 Conclusion . . . . .	6
<b>2 Data Discovering</b> . . . . .	<b>7</b>
2.1 Introduction . . . . .	7
2.2 Structure du Dataset . . . . .	7
2.3 Colonnes Principales . . . . .	8
2.4 Analyse des Données . . . . .	10
2.4.1 Répartition des Classes . . . . .	10
2.4.2 Répartition des Métadonnées . . . . .	11
2.5 Conclusion . . . . .	12
<b>3 Prétraitement des données</b> . . . . .	<b>13</b>
3.1 Introduction . . . . .	13
3.2 Étapes du Prétraitement des Images . . . . .	13
3.2.1 Chargement des Images . . . . .	13
3.2.2 Conversion en Niveaux de Gris . . . . .	14
3.2.3 Amélioration du Contraste avec CLAHE . . . . .	14
3.2.4 Conversion en Couleurs RGB . . . . .	15



3.2.5	Redimensionnement des Images . . . . .	16
3.2.6	Normalisation des Pixels . . . . .	16
3.2.7	Mappage des Classes . . . . .	16
3.2.8	Sous-échantillonnage (Undersampling) . . . . .	17
3.3	Visualisation des Résultats du Prétraitement . . . . .	18
3.4	Conclusion . . . . .	19
<b>4</b>	<b>Modélisation et Évaluation . . . . .</b>	<b>20</b>
4.1	Architecture de VGG16 pour le diagnostic du cancer du sein	20
4.1.1	Base Pré-entraînée : VGG16 . . . . .	21
4.1.2	Couches Supplémentaires Ajoutées pour notre projet .	21
4.1.3	Stratégie d'Entraînement . . . . .	22
4.1.4	Interprétation des Graphiques : Évolution de la Perte et de la Précision pour le Modèle VGG16 . . . . .	23
4.1.5	Courbes ROC et AUC pour évaluer la sensibilité et la spécificité du modèle . . . . .	24
4.2	Architecture de VGG19 pour le diagnostic du cancer du sein	26
4.2.1	Base Pré-entraînée : VGG19 . . . . .	26
4.2.2	Couches Supplémentaires Ajoutées pour notre projet .	27
4.2.3	Stratégie d'Entraînement . . . . .	27
4.2.4	Interprétation des Graphiques : Évolution de la Perte et de la Précision pour le Modèle VGG19 . . . . .	28
4.2.5	Courbes ROC et AUC pour évaluer la sensibilité et la spécificité du modèle . . . . .	29
4.3	Architecture de DenseNet201 pour le diagnostic du cancer du sein . . . . .	30
4.3.1	Base Pré-entraînée : DenseNet201 . . . . .	30
4.3.2	Stratégie d'Entraînement . . . . .	33
4.3.3	Interprétation des Graphiques : Évolution de la Perte et de la Précision pour le Modèle DenseNet205 . . . . .	33
4.3.4	Courbes ROC et AUC pour évaluer la sensibilité et la spécificité du modèle . . . . .	35
4.4	Évaluation des Modèles . . . . .	36
4.5	Conclusion . . . . .	38
<b>5</b>	<b>Réalisation de l'Interface Graphique . . . . .</b>	<b>39</b>
5.1	Outils et Technologies Utilisés . . . . .	39
5.1.1	Visual Studio Code (VSCode) . . . . .	39

5.1.2	Python . . . . .	40
5.1.3	Flask . . . . .	40
5.1.4	HTML/CSS . . . . .	40
5.1.5	Bootstrap . . . . .	41
5.2	Architecture de l'Application . . . . .	41
5.3	Développement de l'Interface Utilisateur . . . . .	41
5.3.1	Page d'Accueil . . . . .	41
5.3.2	Formulaire de Soumission d'Image . . . . .	42
5.3.3	Affichage des Résultats . . . . .	43
5.4	Intégration du Modèle de Prédiction . . . . .	43
5.5	Conclusion . . . . .	44
	<b>Conclusion générale . . . . .</b>	<b>45</b>
	<b>Bibliographie . . . . .</b>	<b>46</b>

# Introduction générale

Le cancer du sein demeure l'une des principales causes de mortalité chez les femmes à travers le monde. Selon l'Organisation Mondiale de la Santé (OMS), une détection précoce peut réduire considérablement le taux de mortalité associé à cette maladie en permettant des interventions médicales plus rapides et mieux ciblées. Dans ce contexte, la mammographie s'impose comme l'outil le plus couramment utilisé pour le dépistage précoce. Cependant, l'analyse manuelle des mammographies reste une tâche complexe, sujette à des erreurs humaines et nécessitant une expertise approfondie.

L'émergence des techniques d'apprentissage profond (Deep Learning) a transformé les approches traditionnelles de classification et d'interprétation des données médicales. En particulier, les réseaux de neurones convolutifs (CNN) se sont avérés extrêmement performants pour l'analyse d'images médicales, en surpassant les méthodes classiques dans des domaines tels que la détection des lésions cancéreuses. Ces modèles permettent d'automatiser et d'améliorer la précision des prédictions, offrant ainsi un soutien crucial aux radiologues.

Toutefois, l'efficacité des modèles de Deep Learning repose fortement sur la qualité des données utilisées. Dans le cadre de la classification des mammographies, un prétraitement des données rigoureux est indispensable pour optimiser les performances des modèles. Ce processus inclut des étapes telles que la normalisation des pixels, l'amélioration du contraste (par exemple, via CLAHE), et l'équilibrage des classes pour éviter des biais dans les prédictions. Une préparation minutieuse des données garantit que les modèles apprennent efficacement à différencier les mammographies positives des négatives.

Ce projet vise à évaluer les performances de trois architectures CNN de pointe – VGG16, VGG19 et DenseNet201 – dans la classification binaire des images de mammographies en deux catégories : positif et négatif. À travers l'utilisation du dataset CBIS-DDSM, nous explorons l'impact du

prétraitement des données, ainsi que la pertinence des métriques telles que la précision, le rappel et le score F1 pour évaluer les performances des modèles. En combinant une approche méthodique de préparation des données et des architectures avancées, ce travail contribue à démontrer le potentiel des outils d'apprentissage profond pour améliorer le dépistage du cancer du sein.

# Chapitre 1

## Contexte général du projet

### 1.1 Introduction

Le dépistage précoce du cancer du sein est essentiel pour améliorer les chances de survie des patientes et réduire les coûts associés à un traitement tardif. Parmi les différentes techniques disponibles, la mammographie est actuellement le standard de référence pour identifier les anomalies mammaires à un stade précoce. Cependant, cette méthode n'est pas exempte de limitations, notamment en raison de l'interprétation subjective des images et des contraintes liées à la charge de travail des radiologues.

Avec l'émergence des technologies d'intelligence artificielle (IA) et, en particulier, du Deep Learning, de nouvelles opportunités se dessinent pour améliorer la précision et la fiabilité des diagnostics mammographiques. Ces outils automatisés permettent d'analyser rapidement et efficacement de grandes quantités d'images, tout en réduisant les erreurs humaines.

Ce chapitre pose les bases de cette recherche en présentant le contexte du dépistage mammographique, les défis qui lui sont associés, et les objectifs de ce travail. Une vue d'ensemble de la méthodologie adoptée et du plan du rapport est également fournie pour guider la lecture et situer cette étude dans un cadre cohérent.

### 1.2 Contexte générale

Le cancer du sein est l'une des principales causes de mortalité chez les femmes dans le monde entier. Selon l'Organisation Mondiale de la Santé (OMS), des millions de nouveaux cas sont diagnostiqués chaque année, et

le dépistage précoce est essentiel pour améliorer les chances de survie. Les mammographies sont aujourd’hui l’outil standard pour détecter les anomalies mammaires à un stade précoce. Cependant, malgré leur efficacité, ces examens sont souvent limités par des facteurs tels que la qualité des images, les variations inter-lecteurs (radiologues), et la complexité des tissus mammaires denses, ce qui peut rendre l’interprétation difficile.

Dans ce contexte, les avancées en intelligence artificielle, et plus spécifiquement en Deep Learning, ouvrent de nouvelles perspectives pour améliorer la précision et la fiabilité des dépistages mammographiques.

### 1.3 Problématique

Malgré les progrès technologiques dans les techniques d’imagerie, le dépistage mammographique reste confronté à plusieurs défis majeurs :

- **Faux positifs et faux négatifs** : Les mammographies peuvent parfois conduire à des interprétations incorrectes, entraînant soit des diagnostics inutiles (anxiété pour la patiente, procédures invasives inutiles) soit des cancers non détectés à un stade précoce.
- **Charge de travail des radiologues** : L’augmentation du volume d’images à analyser peut accroître le risque d’erreurs humaines, en particulier dans des contextes où les ressources médicales sont limitées.
- **Variabilité inter-lecteurs** : Les diagnostics peuvent varier d’un radiologue à un autre, rendant les résultats moins reproductibles.

Ces limitations mettent en évidence la nécessité de solutions automatiques robustes, précises et fiables pour assister les professionnels de santé. Le Deep Learning, avec sa capacité à analyser des volumes massifs de données et à extraire des caractéristiques complexes, s’avère être une technologie prometteuse pour répondre à ces défis.

### 1.4 Objectif de l’étude

L’objectif principal de ce travail est d’explorer l’application des techniques de Deep Learning pour améliorer la détection des anomalies mammaires à partir d’images mammographiques. L’idée est de développer et

d'évaluer des modèles capables de :

- Identifier automatiquement les zones suspectes sur les mammographies.
- Réduire les taux de faux positifs et négatifs.
- Apporter une assistance fiable aux radiologues pour une prise de décision éclairée et plus rapide.

Ce projet vise donc à démontrer comment le Deep Learning peut être intégré dans le processus de dépistage pour accroître l'efficacité et la précision des diagnostics.

### 1.5 Méthodologie générale

Pour atteindre ces objectifs, une approche méthodique sera adoptée. Ce processus est illustré dans la figure ci-dessous, et chaque étape sera détaillée dans les chapitres suivants.

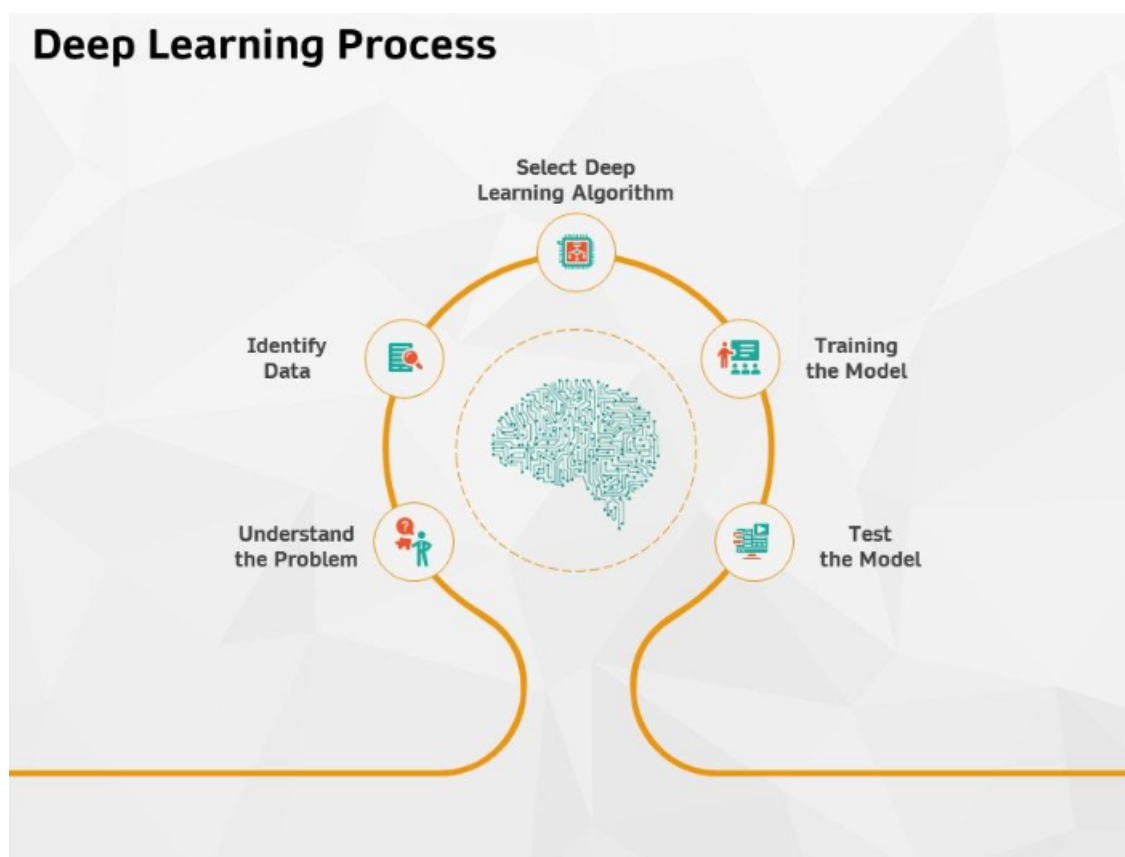


FIG. 1.1 : Architecture du processus de modélisation et d'évaluation des modèles de Deep Learning pour la détection du cancer du sein

Les étapes principales de la méthodologie sont les suivantes :

- **Prétraitement des données** : Les images mammographiques seront normalisées et prétraitées pour garantir une qualité optimale des données d'entrée.
- **Développement des modèles** : Des réseaux de neurones convolutifs (CNN) tels que VGG16, VGG19 et DenseNet seront utilisés pour détecter et classer les anomalies.
- **Entraînement du modèle** : Les modèles seront entraînés sur des images étiquetées pour différencier les classes **positives** et **négatives**.
- **Évaluation des performances** : Les modèles seront évalués à l'aide des métriques suivantes :
  - **Accuracy** : Mesure globale de la proportion des prédictions correctes.
  - **Precision** : Taux de précision des prédictions positives, indiquant la fiabilité du modèle pour identifier les patientes malades (positives).
  - **Recall (Sensibilité)** : Taux de détection des patientes malades parmi toutes les patientes réellement malades (positives).
  - **F1 Score** : Moyenne harmonique entre la précision et la sensibilité, fournissant une mesure équilibrée entre ces deux métriques.
- **Comparaison entre les modèles** : Les performances des modèles VGG16, VGG19 et DenseNet seront comparées en fonction des métriques ci-dessus pour déterminer celui qui présente les meilleures performances dans la détection des anomalies mammaires.

## 1.6 Conclusion

Ce premier chapitre a posé les bases de l'étude en présentant le contexte du dépistage mammographique, les défis actuels, ainsi que l'intérêt croissant d'intégrer des techniques de Deep Learning pour surmonter ces limitations. Le chapitre suivant sera dédié à la présentation du dataset utilisé dans cette étude, le *CBIS-DDSM Breast Cancer Image Dataset*, disponible sur Kaggle, qui constitue la base de données essentielle pour l'entraînement des modèles de classification.



# Chapitre 2

## Data Discovering

### 2.1 Introduction

Le dataset utilisé dans ce projet est le CBIS-DDSM (Curated Breast Imaging Subset of DDSM), une base de données dédiée à l'analyse des mammographies pour le dépistage du cancer du sein. Il contient des mammographies annotées avec des informations détaillées sur les anomalies détectées, telles que les masses et les calcifications, et leurs classifications en bénignes ou malignes. Ce dataset a été choisi en raison de sa richesse et de sa pertinence pour les applications de classification via des modèles d'apprentissage profond.

### 2.2 Structure du Dataset

Le dataset CBIS-DDSM est organisé en plusieurs fichiers :

- `calc_case_description_train_set.csv` et `calc_case_description_test_set.csv` :  
Contiennent les informations relatives aux calcifications.
- `mass_case_description_train_set.csv` et `mass_case_description_test_set.csv` :  
Contiennent les informations sur les masses.
- `dicom_info.csv` et `meta.csv` : Fournissent des métadonnées supplémentaires sur les patients et les images.

Fichier	Description	Taille
<code>calc_case_description_train_set.csv</code>	Informations sur les calcifications (train)	1546 lignes, 14 colonnes
<code>calc_case_description_test_set.csv</code>	Informations sur les calcifications (test)	326 lignes, 14 colonnes
<code>mass_case_description_train_set.csv</code>	Informations sur les masses (train)	1318 lignes, 14 colonnes
<code>mass_case_description_test_set.csv</code>	Informations sur les masses (test)	378 lignes, 14 colonnes

FIG. 2.1 : Structure du DataSet

### 2.3 Colonnes Principales

- `patient_id` : Chaque patiente possède un identifiant unique permettant de relier les métadonnées aux images correspondantes. Cela garantit l'unicité des données.

- `left_or_right_breast` : Cette colonne indique si l'image correspond au sein gauche ou droit. Cette distinction est importante pour des analyses spécifiques par latéralité.

- `image_view` : La vue utilisée pour capturer l'image peut être :

- CC (Craniocaudal) : Vue horizontale de la poitrine.
- MLO (Mediolateral Oblique) : Vue oblique qui est la plus utilisée pour détecter les anomalies.

- `abnormality_id` : Identifiant numérique unique associé à chaque anomalie. Cela permet de suivre une anomalie spécifique dans les différentes images.

- `abnormality_type` : Le type d'anomalie est soit une masse soit une calcification. Cette information est cruciale pour entraîner des modèles distincts si nécessaire.

`mass_shape` : Décrit la forme de la masse détectée, par exemple :

- round (ronde) : Souvent associée à des lésions bénignes.
- irregular (irrégulière) : Peut indiquer une pathologie maligne.

- mass\_margins : Décrit les marges de la masse :
  - circumscribed : Marges bien définies, généralement bénignes.
  - spiculated : Marges diffusées, souvent associées à des anomalies malignes.
- pathology : Indique si l'anomalie est bénigne ou maligne. Cette colonne est utilisée comme label pour l'entraînement des modèles.
- image\_file\_path : Contient le chemin d'accès aux images brutes. Ces images sont utilisées pour les étapes de prétraitement et pour entraîner les modèles.
- ROI\_mask\_file\_path : Contient le chemin vers les masques définissant les régions d'intérêt (ROI) où l'anomalie est localisée.
- breast\_density : Catégorie représentant la densité mammaire :
  - 1 : Faible densité (principalement graisseuse).
  - 4 : Haute densité (tissu glandulaire dense, rendant les anomalies plus difficiles à détecter).

Colonne	Description	Exemple
patient_id	Identifiant unique pour chaque patient	123456
left_or_right_breast	Indique si l'image correspond au sein gauche ou droit	left , right
image_view	Vue de l'image (craniocaudal, mediolateral oblique)	CC , MLO
abnormality_type	Type d'anomalie détectée	mass , calcification
mass_shape	Forme de la masse (si applicable)	round , oval
mass_margins	Marges de la masse (si applicable)	circumscribed , spiculated
image_file_path	Chemin d'accès à l'image brute	/path/to/image.dcm
ROI_mask_file_path	Chemin du masque de la région d'intérêt (ROI)	/path/to/roi_mask.dcm

FIG. 2.2 : Colonnes importantes du Dataset

## 2.4 Analyse des Données

### 2.4.1 Répartition des Classes




FIG. 2.3 : Répartition des pathologies dans le Dataset du Mass Train




FIG. 2.4 : Répartition des pathologies dans le Dataset du Mass Test

Les graphiques ci-dessus montrent que la répartition des pathologies dans les datasets d'entraînement et de test est déséquilibrée, avec une majorité de pathologies bénignes par rapport aux pathologies malignes.

### Fusion des Datasets :

Dans cette étude, les fichiers CSV contenant les informations sur les masses, à savoir `mass_train` (ensemble d'entraînement) et `mass_test` (ensemble de

test), ont été fusionnés en un seul dataset global. Cela nous a permis d'appliquer des étapes de prétraitement cohérentes sur l'ensemble des données disponibles. La fusion garantit également une plus grande flexibilité dans la redistribution des ensembles d'entraînement, de validation, et de test.

### 2.4.2 Répartition des Métadonnées




FIG. 2.5 : un échantillon de mammographies issues du dataset

La figure ci-dessus présente un échantillon de mammographies issues du dataset, sélectionnées de manière aléatoire pour illustrer les caractéristiques des images et leurs annotations associées. Voici les principaux éléments à noter :

#### Visualisation des Images en Niveaux de Gris :

- Les mammographies sont affichées en niveaux de gris pour conserver leur format d'origine, tel qu'utilisé dans l'analyse clinique et l'entraînement des modèles d'apprentissage profond.
- Chaque image correspond à une région d'intérêt (ROI - Region of Interest) identifiée dans le sein.

**Annotations des Images :** Chaque image est annotée avec deux informations importantes :

- Pathology : Indique si l'anomalie détectée est bénigne (BENIGN) ou maligne (MALIGNANT).
- View : Décrit la vue utilisée pour capturer l'image. Dans cet exemple, les vues incluent principalement :

- MLO (Mediolateral Oblique) : Vue oblique couramment utilisée pour détecter des anomalies.
- CC (Craniocaudal) : Vue horizontale montrant une coupe de la poitrine.

## 2.5 Conclusion

Le dataset CBIS-DDSM offre une base solide pour le développement d'un modèle de classification. Malgré quelques défis, tels que le déséquilibre des classes et les valeurs manquantes, les étapes de prétraitement permettent de s'assurer que les données sont prêtes pour l'entraînement. Le prochain chapitre sera dédié au prétraitement des données, afin de préparer efficacement les données pour l'entraînement des modèles.

# Chapitre 3

## Prétraitement des données

### 3.1 Introduction

Le prétraitement des données constitue une étape essentielle dans la préparation des données avant leur utilisation dans des modèles d'apprentissage automatique, notamment les réseaux de neurones convolutionnels (CNN). Dans le cadre de ce projet, les données traitées proviennent d'images médicales, dont l'objectif est de prédire la pathologie à partir des caractéristiques visuelles. Un bon prétraitement des images peut améliorer la précision du modèle en garantissant que les données sont cohérentes, de haute qualité et adaptées à l'entraînement du modèle.

Ce chapitre décrit les différentes étapes de prétraitement des images suivies pour garantir que les données soient prêtes pour l'apprentissage.

### 3.2 Étapes du Prétraitement des Images

Le prétraitement des images suit plusieurs étapes visant à améliorer leur qualité, à réduire la complexité et à rendre les données compatibles avec le modèle de CNN.

#### 3.2.1 Chargement des Images

La première étape consiste à charger les images depuis leurs emplacements respectifs. Chaque image est lue à partir d'un chemin spécifié. Cette étape permet d'assurer que toutes les données sont correctement importées et disponibles pour les étapes suivantes.

Full Mammograms :




FIG. 3.1 : Exemple d'images du DataSet

### 3.2.2 Conversion en Niveaux de Gris

Les images sont ensuite converties en niveaux de gris. Cette transformation est effectuée principalement pour deux raisons :

- Les réseaux de neurones convolutionnels traitent souvent des images en niveaux de gris, car elles contiennent déjà suffisamment d'informations essentielles pour la reconnaissance de motifs, sans la complexité supplémentaire des couleurs.
- Cette conversion est également une étape préalable à l'application d'algorithmes d'amélioration du contraste, comme l'égalisation de l'histogramme.

### 3.2.3 Amélioration du Contraste avec CLAHE

Une des étapes clés du prétraitement est l'application de l'algorithme CLAHE (Contrast Limited Adaptive Histogram Equalization). CLAHE est utilisé pour améliorer localement le contraste des images, ce qui est crucial dans le contexte médical, où des détails fins peuvent être difficiles à distinguer. Cette technique ajuste l'intensité de la lumière sur de petites zones de l'image, ce qui améliore la visibilité des structures internes, comme celles présentes dans les images radiologiques.






FIG. 3.2 : Comparaison des histogrammes avant et après l'application de CLAHE

### 1. Observation :

- *Avant CLAHE* : Concentration des pixels sur les basses intensités (image sombre).
- *Après CLAHE* : Répartition plus uniforme des intensités, pic restant bas.

### 2. Interprétation :

- *Avant* : Contraste limité, typique des images médicales.
- *Après* : Meilleure visibilité des détails sans altérer la nature de l'image.

3. **Conclusion** : CLAHE améliore localement le contraste sans déformer l'image, aidant à détecter des détails fins.

### 3.2.4 Conversion en Couleurs RGB

Après l'amélioration du contraste, les images en niveaux de gris sont converties en images RGB. Bien que l'image ait été initialement convertie en niveaux de gris pour le prétraitement, le format RGB est requis pour la compatibilité avec les réseaux de neurones qui attendent des images à trois canaux. Cette conversion permet de maintenir une structure uniforme et assure que les images sont prêtes à être traitées par le modèle.

### 3.2.5 Redimensionnement des Images

Les images doivent être redimensionnées pour avoir une taille uniforme avant d'être alimentées dans le modèle. Le redimensionnement permet de garantir que toutes les images possèdent la même dimension, ce qui est une exigence pour l'entraînement des modèles d'apprentissage automatique. Cela permet également de réduire la complexité des données, facilitant ainsi l'apprentissage tout en réduisant les exigences en termes de mémoire et de puissance de calcul.

### 3.2.6 Normalisation des Pixels

La normalisation des pixels est une étape importante qui consiste à mettre à l'échelle les valeurs des pixels de l'image entre 0 et 1. Cela est fait en divisant chaque valeur de pixel par 255 (valeur maximale possible pour un pixel RGB). Cette normalisation aide à accélérer l'entraînement des modèles, car elle garantit que toutes les caractéristiques (les pixels dans ce cas) ont une échelle similaire, ce qui facilite la convergence du modèle lors de l'entraînement.

### 3.2.7 Mappage des Classes

Une fois les images prétraitées, il est nécessaire de transformer les étiquettes de pathologie en valeurs numériques. Les modèles d'apprentissage automatique ne peuvent traiter que des données numériques, d'où la nécessité de convertir les étiquettes catégorielles (par exemple, 'MALIGNANT', 'BENIGN', 'BENIGN\_WITHOUT\_CALLBACK') en valeurs binaires ou entières. Dans notre cas, les étiquettes sont mappées comme suit : 'MALIGNANT' et 'BENIGN' sont associées à la valeur 1, tandis que 'BENIGN\_WITHOUT\_CALLBACK' est associée à la valeur 0. Cette étape permet de préparer les étiquettes pour l'entraînement du modèle.

```
labels
1    1555
0     141
Name: count, dtype: int64
```

Répartition des types de masses dans les données




FIG. 3.3 : Mappage des étiquettes de pathologie

### 3.2.8 Sous-échantillonnage (Undersampling)

Lors de l'analyse des données étiquetées, nous avons observé un déséquilibre dans la répartition des classes. Plus précisément, la classe 1 (représentant les échantillons **MALIGNANT**) compte 1555 échantillons, tandis que la classe 0 (représentant les échantillons **BENIGN\_WITHOUT\_CALLBACK**) en compte seulement 141. Ce déséquilibre peut entraîner un modèle biaisé, favorisant la classe majoritaire. Pour y remédier, nous avons appliqué une technique de sous-échantillonnage (undersampling) sur la classe majoritaire.

L'undersampling consiste à réduire le nombre d'exemples de la classe dominante pour équilibrer les classes. Dans notre cas, nous avons réduit le nombre d'exemples de la classe 1 (les **MALIGNANT**) pour le rendre équivalent à celui de la classe 0 (les **BENIGN\_WITHOUT\_CALLBACK**), créant ainsi un jeu de données équilibré. Cette méthode est cruciale pour améliorer la performance du modèle, en évitant que la classe majoritaire (classe 1) ne domine l'apprentissage et en permettant au modèle de mieux identifier les caractéristiques de la classe minoritaire (classe 0).

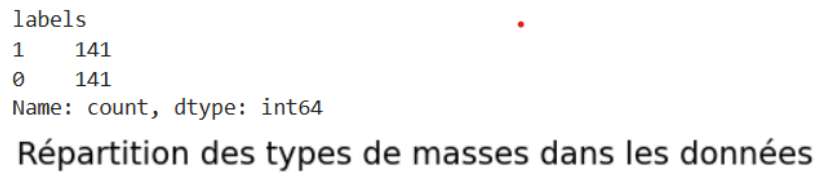


FIG. 3.4 : Équilibrage des classes suite à l'undersampling

Après l'undersampling, chaque classe possède un nombre équivalent d'exemples, ce qui améliore la capacité de généralisation du modèle lors de l'entraînement.

### 3.3 Visualisation des Résultats du Prétraitement

Afin de valider l'efficacité du prétraitement, il est important de visualiser les images avant et après les transformations. Cette comparaison permet de s'assurer que les étapes de prétraitement n'ont pas altéré les informations pertinentes tout en améliorant la qualité des images. Une fonction de visualisation permet de montrer les images d'origine et leurs versions traitées côte à côte pour un échantillon d'images.




FIG. 3.5 : Comparaison des images avant et après prétraitement

### 3.4 Conclusion

Le prétraitement des images a permis d'améliorer la qualité des données en appliquant des techniques telles que l'amélioration du contraste, la conversion en niveaux de gris, la normalisation des pixels, et le sous-échantillonnage pour équilibrer les classes. Ces étapes ont optimisé les données pour l'entraînement du modèle tout en réduisant les risques de surapprentissage.

Nous pouvons maintenant passer à la modélisation et à l'évaluation des modèles, qui seront abordées dans le chapitre suivant.

# Chapitre 4

## Modélisation et Évaluation

Ce chapitre met l'accent sur les étapes de modélisation et d'évaluation des modèles utilisés dans la détection du cancer du sein, notamment l'entraînement et l'évaluation, ce qui est essentiel pour garantir des prédictions fiables et précises.

Pour ce projet, nous avons expérimenté avec trois architectures de réseaux de neurones convolutifs (CNN) bien connues : VGG16, VGG19 et DenseNet. Ces architectures ont été choisies pour leur capacité à capturer des caractéristiques complexes tout en s'adaptant à la nature visuelle particulière des mammographies.

### 4.1 Architecture de VGG16 pour le diagnostic du cancer du sein




FIG. 4.1 : Architecture de VGG16 adaptée pour le diagnostic du cancer du sein.

### 4.1.1 Base Pré-entraînée : VGG16

#### Structure de la base VGG16 :

- Le modèle VGG16 est composé de 13 couches convolutives et de 3 couches entièrement connectées, organisées en 5 blocs convolutifs.
- Chaque couche convolutive applique des filtres de taille 3x3, optimisés pour extraire des caractéristiques locales telles que les bords, textures, et formes complexes.
- Après chaque groupe de convolutions, une couche de max-pooling est appliquée pour réduire la taille des cartes de caractéristiques tout en conservant les informations essentielles et en diminuant la complexité computationnelle.

#### Avantage du pré-entraînement :

- Les poids pré-entraînés sur le dataset ImageNet permettent au modèle d'extraire efficacement des caractéristiques visuelles significatives, même lorsqu'il est appliqué à un dataset médical restreint comme celui des mammographies.
- Cette approche réduit considérablement le temps d'entraînement tout en augmentant la précision globale du modèle.

**Modifications :** La couche de sortie originale (softmax pour 1000 classes sur ImageNet) a été retirée pour adapter le modèle à une tâche de classification binaire.

### 4.1.2 Couches Supplémentaires Ajoutées pour notre projet

Pour adapter VGG16 à la classification binaire des mammographies, plusieurs couches personnalisées ont été ajoutées au modèle :

- **Couches de Regularization :**
  - **Batch Normalization :** Ajoutée après chaque couche dense, elle stabilise l'entraînement en normalisant les activations des neurones. Il Améaiore la vitesse de convergence tout en limitant les oscillations dans les gradients.
  - **Dropout (0.2) :** Introduit pour prévenir le surapprentissage, en désactivant aléatoirement une fraction des neurones lors de l'entraînement.
- **Couches Dense :** Trois couches entièrement connectées supplémentaires ont été ajoutées :  
Chaque couche contient 1024 neurones avec une activation ReLU, permettant au modèle d'apprendre des représentations complexes et spécifiques aux anomalies des mammographies.
- **Couche de Sortie :** Une seule unité dense avec une activation sigmoïde a été utilisée pour produire une probabilité binaire, indiquant si une image représente un cancer ou un non-cancer.

### 4.1.3 Stratégie d'Entraînement

#### **Gel des Couches de VGG16 :**

Les couches de la base pré-entraînée de VGG16 ont été gelées pour empêcher leur mise à jour lors de l'entraînement initial. Cela permet de concentrer l'entraînement sur les couches ajoutées, tout en conservant les connaissances générales des poids pré-entraînés.

#### **Fonction de Perte :**

Une perte de Binary Crossentropy a été utilisée, car elle est spécifiquement adaptée aux tâches de classification binaire, en pénalisant fortement les prédictions incorrectes.

#### **Optimiseur :**

L'optimiseur Adam avec un learning rate de  $1e-4$  a été sélectionné pour sa capacité à ajuster dynamiquement les taux d'apprentissage, ce qui permet une convergence rapide et stable.



### 4.1.4 Interprétation des Graphiques : Évolution de la Perte et de la Précision pour le Modèle VGG16

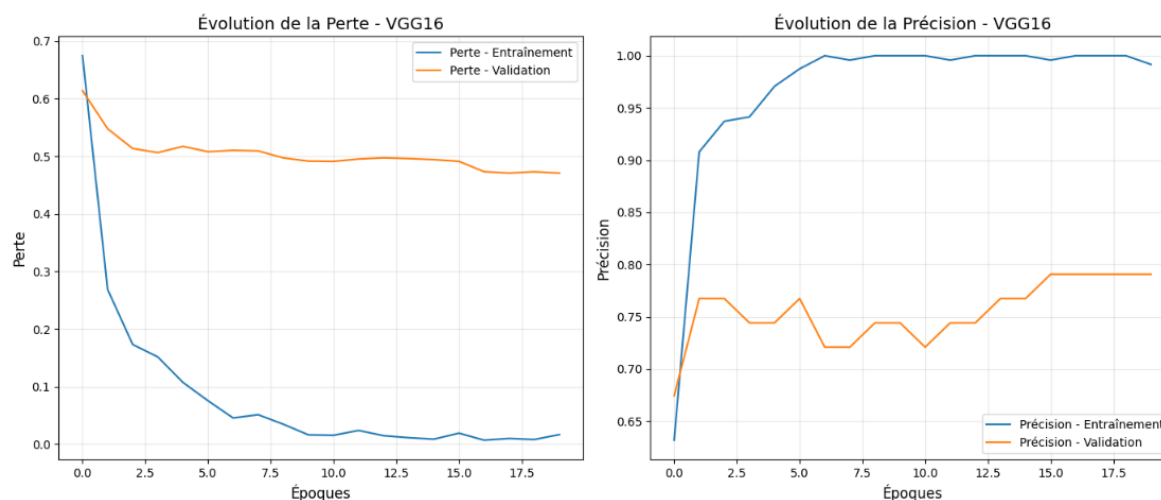


FIG. 4.2 : Évolution de la Perte et de la Précision pour le Modèle VGG16

Les graphiques ci-dessus présentent l'évolution de la perte et de la précision du modèle VGG16 pour les ensembles d'entraînement et de validation au fil des époques.

#### a. Observation :

- La **perte d'entraînement** (courbe bleue) diminue de façon régulière, atteignant une valeur proche de 0 après environ 15 époques.
- La **perte de validation** (courbe orange) diminue initialement, mais tend à stagner après environ 5 époques, autour de 0.5.

#### b. Interprétation :

- La diminution continue de la perte d'entraînement montre que le modèle optimise correctement son erreur sur l'ensemble d'entraînement.
- La stagnation de la perte de validation après quelques époques indique que le modèle pourrait avoir atteint sa capacité maximale de généralisation sur les données de validation, sans toutefois montrer de signes marqués de surapprentissage.

#### Analyse de la Précision :

##### a. Observation :

- La **précision d'entraînement** (courbe bleue) augmente rapidement, atteignant presque 1.0 (100%) après environ 10 époques.
- La **précision de validation** (courbe orange) progresse initialement, atteignant un plateau autour de 0.75, avec de légères fluctuations après les 5

premières époques.

### b. Interprétation :

- La précision élevée sur l'entraînement témoigne de la capacité du modèle à apprendre efficacement à partir des données fournies.
- Cependant, le plateau de la précision de validation montre que le modèle ne généralise pas aussi bien qu'il apprend. Les fluctuations mineures pourraient être dues à des variations naturelles dans les données ou à un éventuel léger déséquilibre entre les classes.

## 4.1.5 Courbes ROC et AUC pour évaluer la sensibilité et la spécificité du modèle




FIG. 4.3 : Courbe ROC pour le Modèle VGG16

La courbe ROC (Receiver Operating Characteristic) présentée évalue la performance du modèle VGG16 pour la classification binaire des mammographies (cancer vs non-cancer). Voici une analyse détaillée :

### 1. AUC (Area Under Curve)

**AUC = 0.91 :**

- L'aire sous la courbe (AUC) est de 0.91, ce qui indique que le modèle a une très bonne capacité de discrimination entre les classes positives (cancer) et négatives (non-cancer).
- Une AUC proche de 1.0 est idéale, tandis qu'une AUC de 0.5 (ligne grise) correspond à une performance aléatoire.

### **2. TPR (True Positive Rate) vs. FPR (False Positive Rate)**

**True Positive Rate (TPR) :**

- C'est le pourcentage de cas positifs correctement identifiés par le modèle (sensibilité).
- Plus le TPR est élevé, plus le modèle détecte efficacement les cas positifs (cancer).

**False Positive Rate (FPR) :**

- C'est le pourcentage de cas négatifs incorrectement classifiés comme positifs.
- Un faible FPR montre que le modèle fait peu d'erreurs dans les classifications négatives.

### **3. Performance Générale**

- La courbe est bien au-dessus de la diagonale (ligne grise), indiquant que le modèle est bien meilleur que le hasard.
- Les résultats montrent que le modèle atteint un bon équilibre entre la sensibilité (detection des cas positifs) et la spécificité (éviter les faux positifs).

## 4.2 Architecture de VGG19 pour le diagnostic du cancer du sein

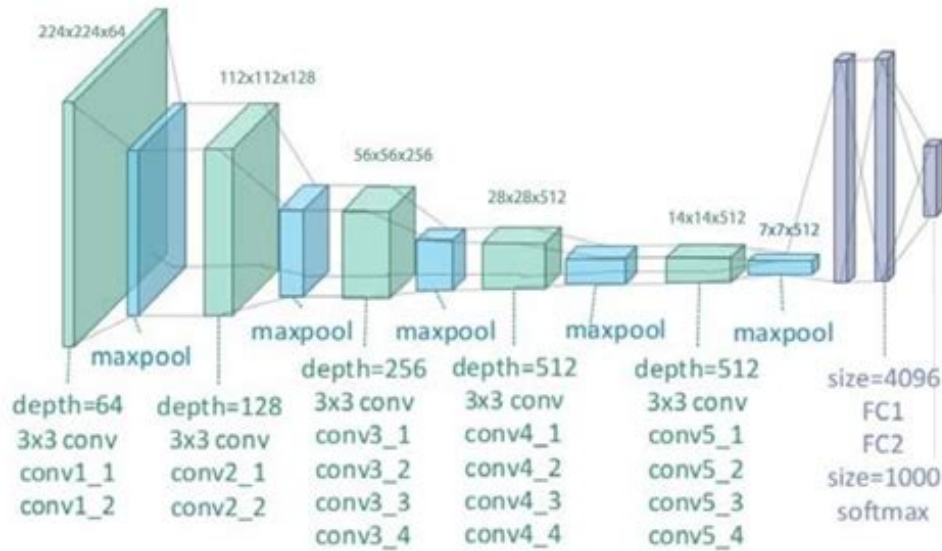


FIG. 4.4 : Architecture de VGG19 adaptée pour le diagnostic du cancer du sein.

### 4.2.1 Base Pré-entraînée : VGG19

#### Structure de la base VGG19 :

- Le modèle VGG19 est constitué de 16 couches convolutives et 3 couches entièrement connectées.
- Chaque couche convolutive utilise des filtres de taille 3x3 pour extraire des caractéristiques locales telles que les bords, textures, et formes complexes.
- Des couches de max-pooling suivent chaque groupe de convolutions pour réduire la taille des cartes de caractéristiques tout en conservant les informations essentielles.

#### Avantage du pré-entraînement :

- Les poids pré-entraînés sur ImageNet permettent une extraction efficace des caractéristiques visuelles, même avec un dataset médical plus restreint.
- Cela réduit considérablement le temps d'entraînement tout en améliorant les performances globales.

**Modifications :** La couche finale (softmax pour 1000 classes d'ImageNet) a été retirée pour adapter le modèle à une tâche de classification binaire.

### 4.2.2 Couches Supplémentaires Ajoutées pour notre projet

Pour améliorer la capacité de VGG19 à détecter les anomalies spécifiques dans les mammographies, plusieurs couches personnalisées ont été ajoutées au modèle :

- **Couches de Regularization :**
  - **Batch Normalization :** Ajoutée après chaque couche dense pour stabiliser l'entraînement et améliorer la convergence.
  - **Dropout (0.2) :** Introduite pour réduire le surapprentissage en désactivant aléatoirement des neurones lors de l'entraînement.
- **Couches Dense :** Trois couches entièrement connectées ont été ajoutées, chacune avec 1024 neurones et une activation ReLU. Ces couches permettent au modèle d'apprendre des représentations complexes nécessaires à la classification.
- **Couche de Sortie :** Une seule unité dense avec une activation sigmoïde a été ajoutée pour produire une probabilité binaire indiquant la classe de l'image (cancer ou non-cancer).

### 4.2.3 Stratégie d'Entraînement

#### **Gel des Couches de VGG19 :**

Les poids des couches de la base VGG19 ont été gelés, empêchant leur mise à jour lors de l'entraînement initial. Cela permet de concentrer l'entraînement sur les couches supplémentaires.

#### **Fonction de Perte :**

Une perte de Binary Crossentropy a été utilisée, adaptée aux tâches de classification binaire.

#### **Optimiseur :**

L'optimiseur Adam avec un learning rate de  $1e-4$  a été choisi pour sa capacité à s'adapter dynamiquement au gradient pendant l'entraînement.

### 4.2.4 Interprétation des Graphiques : Évolution de la Perte et de la Précision pour le Modèle VGG19

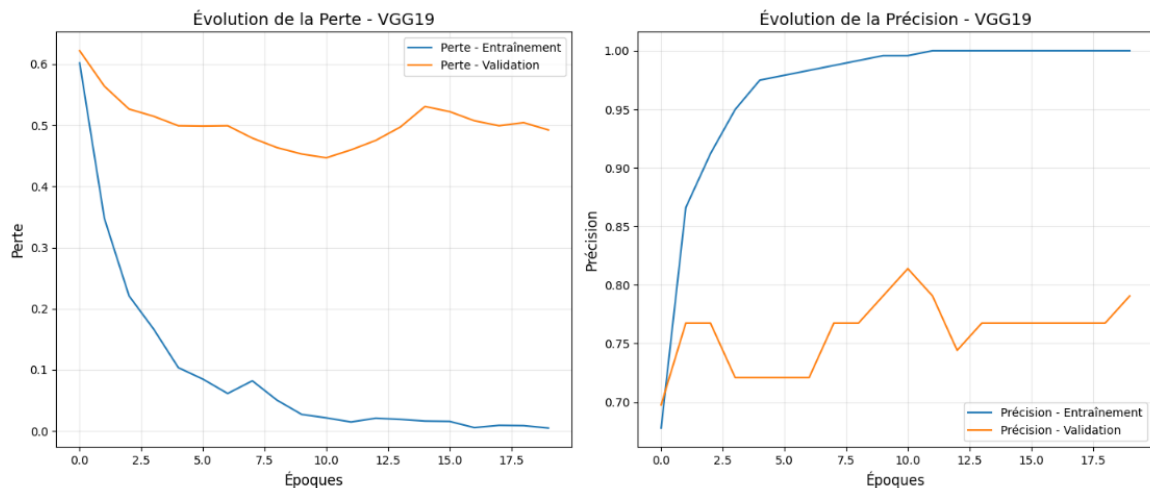


FIG. 4.5 : Évolution de la Perte et de la Précision pour le Modèle VGG19

#### Analyse de la Perte :

##### a. Observation :

- La **perte d'entraînement** (courbe bleue) diminue régulièrement au fur et à mesure des époques, ce qui indique que le modèle apprend bien à minimiser l'erreur sur les données d'entraînement.
- La **perte de validation** (courbe orange) suit initialement une tendance décroissante mais commence à stagner, puis à augmenter légèrement après environ 10 époques.

##### b. Interprétation :

- La diminution continue de la perte d'entraînement reflète une bonne optimisation du modèle sur les données d'entraînement.
- L'augmentation de la perte de validation après la 10<sup>e</sup> époque suggère un surapprentissage (overfitting). Cela signifie que le modèle commence à mémoriser les données d'entraînement au lieu de généraliser aux nouvelles données.

#### Analyse de la Précision :

##### a. Observation :

- La **précision d'entraînement** (courbe bleue) augmente rapidement et atteint presque 1.0 après environ 10 époques, indiquant une très bonne capacité du modèle à classer correctement les données d'entraînement.
- La **précision de validation** (courbe orange) atteint un plateau autour de 0.75 à 0.8 et montre des fluctuations significatives après la 10 époque.

### b. Interprétation :

- La haute précision d'entraînement combinée à une précision de validation plus faible et instable est un signe supplémentaire de surapprentissage.
- Les fluctuations de la précision de validation peuvent également indiquer une sensibilité aux variations dans l'ensemble de validation ou un déséquilibre entre les classes.

### 4.2.5 Courbes ROC et AUC pour évaluer la sensibilité et la spécificité du modèle




FIG. 4.6 : Courbe ROC pour le Modèle VGG19

La courbe ROC (Receiver Operating Characteristic) présentée illustre la capacité du modèle VGG19 à différencier entre les classes positives (cancer) et négatives (non-cancer). Elle est basée sur les prédictions du modèle sur l'ensemble de test.

### 1. AUC (Area Under Curve)

**AUC = 0.90 :**

- L'AUC mesure la capacité globale du modèle à classer correctement les cas positifs et négatifs.
- Une AUC de 0.90 indique que le modèle a une excellente capacité de discrimination.

### 2. TPR (True Positive Rate) vs. FPR (False Positive Rate)

**True Positive Rate (TPR) :**

- C'est le pourcentage de cas positifs correctement identifiés par le modèle (sensibilité).
- Un TPR élevé indique une forte capacité à identifier les cas de cancer.

**False Positive Rate (FPR) :**

- C'est le pourcentage de cas négatifs incorrectement classifiés comme positifs.
- Un faible FPR est souhaitable pour limiter les faux positifs, qui peuvent entraîner des erreurs coûteuses (anxiété des patients, examens inutiles).

### 3. Performance Générale

- La courbe ROC est bien au-dessus de la ligne diagonale (performance aléatoire), ce qui confirme la supériorité du modèle VGG19 pour cette tâche.
- La forme en escalier reflète les variations des seuils utilisés pour classer les probabilités prédictives, démontrant une performance robuste sur plusieurs seuils.

## 4.3 Architecture de DenseNet201 pour le diagnostic du cancer du sein

### 4.3.1 Base Pré-entraînée : DenseNet201

**Structure de la base DenseNet201 :** DenseNet201 est un modèle profond composé de 201 couches organisées en blocs denses. Chaque couche d'un bloc dense est connectée à toutes les couches précédentes, ce qui amé-



liore la réutilisation des caractéristiques et la propagation des gradients tout en réduisant le nombre total de paramètres.




FIG. 4.7 : Architecture de DenseNet.

Dans ce projet, le modèle DenseNet201 a été configuré sans ses poids pré-entraînés ImageNet afin de charger un ensemble de poids personnalisé à partir d'un chemin local spécifique.

La couche dense finale (`include_top=False`) a été exclue pour permettre l'ajout de nouvelles couches personnalisées adaptées à la classification binaire.

**Modifications :** Les couches ajoutées incluent :

- **Dropout** : Réduit le surapprentissage en désactivant aléatoirement 20% des neurones à chaque couche dense.
- **Flatten** : Transforme les cartes de caractéristiques 2D en un vecteur 1D pour les couches entièrement connectées.
- **Batch Normalization** : Stabilise et accélère l'entraînement en normalisant les activations.
- **Couches Dense** : Trois couches entièrement connectées avec 1024 neurones chacune, utilisant une initialisation He-uniform et une activation ReLU.
- **Couche de Sortie** : Une unité dense avec une activation sigmoïde pour fournir une probabilité pour chaque classe.

### 4.3.2 Stratégie d'Entraînement

**Gel des Couches :** Toutes les couches de DenseNet201 ont été gelées (`trainable=False`) lors de l'entraînement initial pour préserver les poids préchargés. Cela a permis de concentrer l'entraînement sur les nouvelles couches ajoutées.

**Compilation :**

- **Optimiseur :** Adam avec un taux d'apprentissage ( $1e - 4$ ) ajusté pour des mises à jour stables des poids.
- **Fonction de Perte :** Binary Crossentropy, adaptée à la classification binaire.
- **Métrique :** Précision (*accuracy*).

**Entraînement :** Le modèle a été entraîné pendant 10 époques avec un batch size de 32. Les données ont été divisées entre un ensemble d'entraînement et un ensemble de validation pour surveiller les performances.

### 4.3.3 Interprétation des Graphiques : Évolution de la Perte et de la Précision pour le Modèle DenseNet205

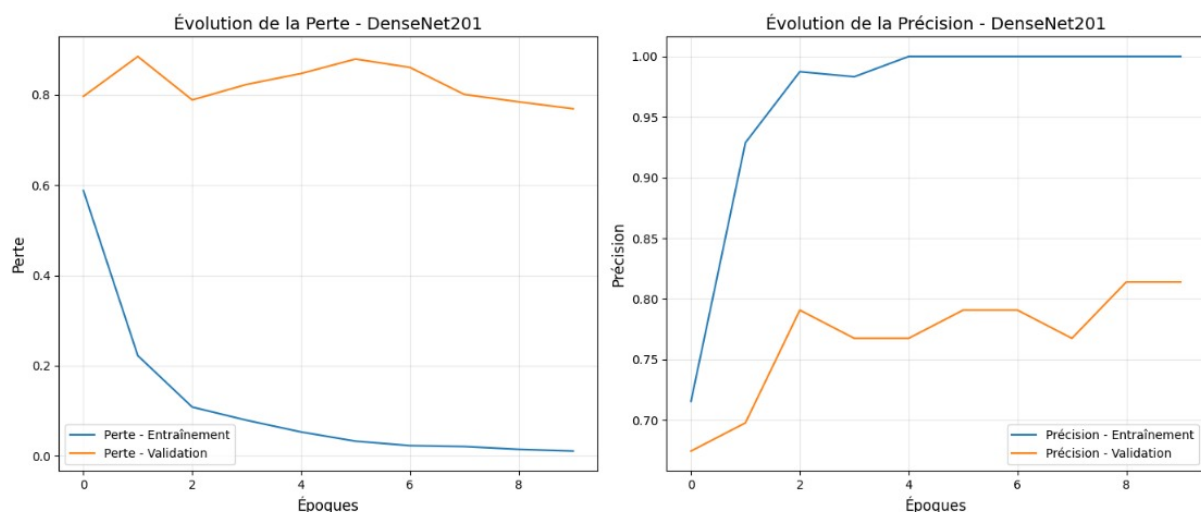


FIG. 4.8 : Évolution de la Perte et de la Précision pour le Modèle DenseNet205

**Analyse de la Perte :**

**a. Observation :**

- La courbe bleue représente la perte durant l'entraînement. Elle diminue

rapidement dès les premières itérations, passant de 0.6 à presque 0, ce qui indique que le modèle converge bien vers un minimum de perte.

- Cette diminution rapide montre que le modèle apprend efficacement les caractéristiques du jeu de données.

### **b. Observation sur la validation :**

- Contrairement à la courbe d'entraînement, la perte de validation diminue initialement, mais se stabilise autour de 0.8 avec une légère tendance à diminuer au fil des époques.

- Cet écart entre la perte d'entraînement et de validation pourrait indiquer un début de surapprentissage (overfitting), car le modèle s'adapte trop aux données d'entraînement tout en généralisant moins bien.

### **Analyse de la Précision :**

#### **a. Précision sur l'entraînement :**

- La courbe bleue montre que la précision d'entraînement atteint rapidement un niveau très élevé ( 0.99) en quelques époques.

- Cela confirme que le modèle s'entraîne efficacement pour classer correctement les images dans le jeu d'entraînement.

#### **b. Précision sur la validation :**

- La précision sur la validation (courbe orange) démarre autour de 0.7 et progresse jusqu'à 0.85, mais reste inférieure à la précision d'entraînement.

- Bien que la précision de validation augmente, l'écart persistant entre les deux courbes indique que le modèle pourrait avoir des difficultés à généraliser sur des données inédites.

### 4.3.4 Courbes ROC et AUC pour évaluer la sensibilité et la spécificité du modèle




FIG. 4.9 : Courbe ROC pour le Modèle DenseNet205

La courbe ROC (Receiver Operating Characteristic) présentée illustre la capacité du modèle VGG19 à différencier entre les classes positives (cancer) et négatives (non-cancer). Elle est basée sur les prédictions du modèle sur l'ensemble de test.

#### 1. AUC (Area Under Curve)

**AUC = 0.84 :**

- L'AUC mesure la capacité globale du modèle à classer correctement les cas positifs et négatifs.
- Une AUC de 0.84 indique que, dans 84 % des cas, le modèle est capable de différencier correctement les patients atteints de cancer de ceux qui ne le sont pas.

#### 2. TPR (True Positive Rate) vs. FPR (False Positive Rate)

**True Positive Rate (TPR) :**

- À un seuil de classification optimal, le modèle atteint un TPR de 0.80 (80%), indiquant qu'il identifie correctement 80 % des cas positifs (cancer) parmi toutes les observations positives.

### False Positive Rate (FPR) :

- À ce même seuil, le FPR est d'environ 0.20 (20%), signifiant que 20 % des cas négatifs (non-cancer) sont incorrectement classifiés comme positifs.
- Ce taux est acceptable mais peut être réduit pour minimiser les faux diagnostics, notamment en affinant les hyperparamètres du modèle ou en appliquant une méthode d'optimisation spécifique.

### 3. Analyse Numérique : Performance Générale

- Courbe : La courbe ROC est bien au-dessus de la diagonale (ligne grise avec  $AUC = 0.5$ ), prouvant que DenseNet201 a une performance significative au-delà du hasard.
- La forme en escalier reflète les variations des seuils utilisés pour classer les probabilités prédictives, démontrant une performance robuste sur plusieurs seuils.

## 4.4 Évaluation des Modèles

Modèle	Précision (Classe 0)	Rappel (Classe 0)	F1- score (Classe 0)	Précision (Classe 1)	Rappel (Classe 1)	F1- score (Classe 1)	Accuracy	Macro Avg	Weighted Avg
VGG16	0.69	1.00	0.81	1.00	0.52	0.69	0.77	0.84	0.84
VGG19	0.61	1.00	0.76	1.00	0.33	0.50	0.67	0.81	0.80
DenseNet201	0.77	0.91	0.83	0.88	0.71	0.79	0.81	0.83	0.82

FIG. 4.10 : Tableau de Synthèse des Résultats

### 1. Précision globale (Accuracy)

- DenseNet201 conserve la meilleure précision globale avec 81 %, suivi par VGG16 avec 77 %.
- VGG19 affiche une performance inférieure avec une précision de seulement 67 %.

### 2. Analyse des performances par classe

#### Classe 0 (Non-cancer)

- Tous les modèles atteignent un rappel parfait (1.00) pour la classe 0, indiquant qu'ils identifient correctement tous les cas non-cancéreux.

- Cependant, DenseNet201 montre une meilleure précision (0.77) pour cette classe, suivi de VGG16 (0.69) et VGG19 (0.61).

#### Classe 1 (Cancer)

- DenseNet201 surpasse les deux autres modèles avec un F1-score équilibré de 0.79, grâce à un bon compromis entre précision (0.88) et rappel (0.71).

- VGG16 et VGG19 affichent des performances très faibles pour la classe 1 en raison d'un rappel particulièrement bas, notamment 0.33 pour VGG19, ce qui reflète une incapacité à détecter une grande proportion de cas de cancer.

### 3. F1-score global

- Le F1-score global est plus élevé pour DenseNet201 (0.83), ce qui montre qu'il est le plus performant dans les deux classes.

- VGG16 présente des performances intermédiaires (0.81), tandis que VGG19 affiche des résultats inférieurs avec un F1-score global de 0.63, montrant sa faiblesse dans la gestion des cas de cancer.

#### Conclusion comparative

- **DenseNet201** se démarque clairement comme le modèle le plus performant, avec une précision globale élevée, un rappel supérieur pour la classe 1 (71 %) et un F1-score global équilibré (0.83).

- **VGG16** offre une performance acceptable mais inférieure à DenseNet201, avec un rappel moyen pour la classe 1 (52 %).

- **VGG19** présente les performances les plus faibles, particulièrement pour la classe 1, où un faible rappel (33 %) limite sa fiabilité pour détecter les cas de cancer.

### 4.5 Conclusion

Sur la base des résultats obtenus, **DenseNet201** est recommandé pour la classification des images mammographiques en tant que modèle principal. Son équilibre entre sensibilité et spécificité en fait un outil prometteur pour aider les professionnels de santé dans le diagnostic précoce du cancer du sein, contribuant ainsi à améliorer les taux de survie des patientes grâce à une détection plus précise et fiable.



# Chapitre 5

## Réalisation de l'Interface Graphique

Ce chapitre décrit la réalisation de l'interface graphique intégrant le modèle DenseNet201 pour le dépistage du cancer du sein, basé sur des images médicales, qui a montré les meilleures performances dans le chapitre précédent.

### 5.1 Outils et Technologies Utilisés

#### 5.1.1 Visual Studio Code (VSCode)



FIG. 5.1 : Visual Studio Code

VSCode a été un outil essentiel tout au long du projet, facilitant le développement collaboratif et la gestion efficace du code. Ses fonctionnalités, telles que la gestion des extensions et le débogage, ont permis de maintenir une haute qualité de code et d'optimiser le développement de l'application web destinée au dépistage du cancer du sein.

### 5.1.2 Python



FIG. 5.2 : Python

Python a été choisi pour ce projet en raison de ses vastes bibliothèques dédiées au traitement des images et à l'apprentissage profond, telles que TensorFlow, Keras et NumPy. Cela a facilité la création d'un modèle performant basé sur l'architecture DenseNet201 pour la détection des cancers du sein.

### 5.1.3 Flask



FIG. 5.3 : Flask

Flask a été sélectionné pour développer le backend de l'application en raison de sa simplicité, de sa flexibilité et de sa capacité à intégrer le modèle de prédiction directement dans une application web. Cette approche garantit une interface fluide et accessible pour les médecins et les patientes.

### 5.1.4 HTML/CSS



FIG. 5.4 : HTML et CSS

HTML et CSS ont été utilisés pour concevoir une interface utilisateur intuitive et réactive. Ces technologies permettent de structurer efficacement

la page et d'améliorer l'expérience utilisateur, en particulier pour afficher des résultats de manière claire et compréhensible.

### 5.1.5 Bootstrap

Bootstrap a été intégré pour accélérer le développement de l'interface graphique. Grâce à ses composants prêts à l'emploi, tels que les boutons, les formulaires et les alertes, l'application offre une expérience utilisateur moderne et conviviale, essentielle pour les patientes et les professionnels de santé.

## 5.2 Architecture de l'Application

L'architecture de l'application web se compose de deux couches principales :

- **Frontend** : Composé de HTML, CSS, JavaScript et Bootstrap pour créer une interface utilisateur ergonomique et attractive.
- **Backend** : Utilisation de Flask pour gérer les requêtes, exécuter le modèle de prédiction basé sur DenseNet201, et retourner les résultats.

## 5.3 Développement de l'Interface Utilisateur

### 5.3.1 Page d'Accueil

La page d'accueil de l'application est conçue pour sensibiliser les utilisateurs à l'importance de la détection précoce du cancer du sein. Elle affiche une image évocatrice avec le message : **"Stay Aware - Breast Cancer Awareness"**. Cette présentation vise à créer une première impression forte et à rappeler l'objectif de l'application : contribuer à la prévention et au diagnostic rapide.



FIG. 5.5 : Page d'accueil de l'application : Sensibilisation au cancer du sein.

La page inclut également un bouton de navigation principal permettant aux utilisateurs d'accéder au formulaire de prédiction. Le design est simple, épuré, et met l'accent sur une navigation intuitive pour garantir une expérience utilisateur agréable.

### 5.3.2 Formulaire de Soumission d'Image

Le formulaire de soumission est situé sur une page dédiée. Il permet aux utilisateurs de télécharger une image médicale (par exemple, une mammographie) en suivant des instructions claires.

The image shows a web form for uploading a breast image. At the top left is a pink heart icon with a ribbon. At the top right are the links 'HOME' and 'DIAGNOSE NOW'. A large pink banner with the text 'Diagnose now' in white is positioned below the navigation links. Below the banner, the text 'Upload Breast Image:' is displayed. Underneath this text is a file selection interface with a button labeled 'Choisir un fichier' and the text 'Aucun Fichier Choisi'. At the bottom of the form is a pink button labeled 'Diagnose'.

FIG. 5.6 : Formulaire de soumission d'image

### 5.3.3 Affichage des Résultats

Les résultats de la prédiction sont affichés sous une forme simple et compréhensible. Pour chaque image soumise, l'application retourne :

- **Prédiction** : Indique si la détection est **Positive** (cancer suspecté) ou **Negative** (pas de signe de cancer détecté).
- **Confiance** : Une valeur numérique comprise entre 0 et 1, exprimant la probabilité associée au résultat.

Un exemple typique de présentation des résultats pourrait ressembler à ceci :

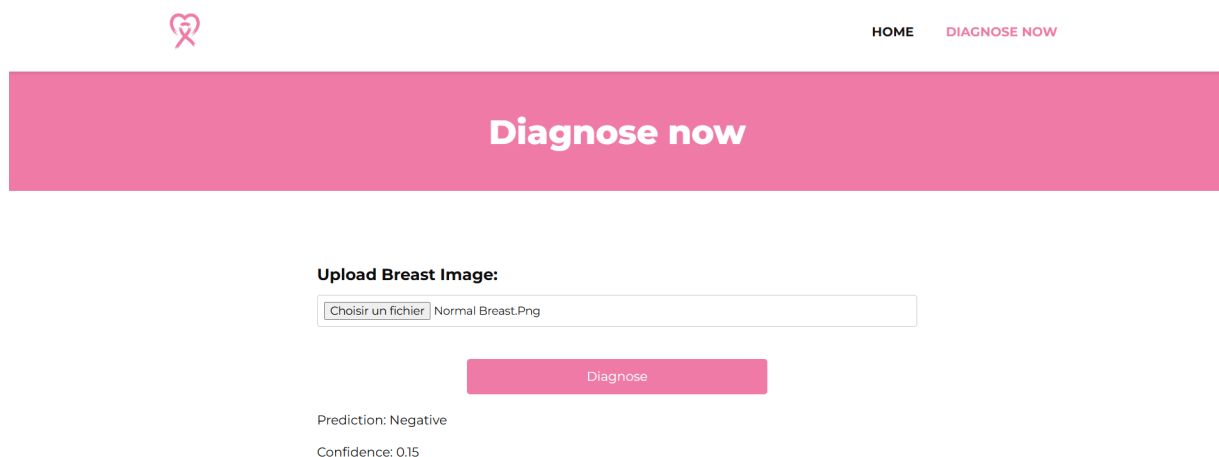


FIG. 5.7 : Affichage des résultats : Prédiction et Confiance.

Ce format d'affichage vise à fournir des informations précises et exploitables, tout en garantissant une interprétation simple pour les utilisateurs.

## 5.4 Intégration du Modèle de Prédiction

Le modèle de prédiction basé sur l'architecture DenseNet201, entraîné sur des images médicales, est intégré dans le backend Flask. Lorsqu'une image est soumise via le formulaire, le backend effectue les étapes suivantes :

- Prétraitement de l'image (redimensionnement, normalisation).

- Exécution de la prédiction pour obtenir un résultat binaire (**Positive/Negative**).
- Transmission du résultat à l'interface utilisateur .

### 5.5 Conclusion

La réalisation de l'interface graphique a permis de fournir un outil interactif et accessible pour faciliter l'utilisation du modèle de prédiction des cancers du sein. Cette interface, pensée pour les médecins et les patientes, représente un pont essentiel entre les avancées technologiques et leur application pratique dans le domaine de la santé.

# Conclusion générale

Ce rapport marque l'aboutissement de notre projet explorant les réseaux de neurones convolutifs (CNN) pour le dépistage précoce du cancer du sein. L'objectif principal était d'évaluer les performances des architectures CNN VGG16, VGG19 et DenseNet201 dans la classification binaire des mammographies. Nous avons mis l'accent sur un prétraitement rigoureux des données incluant la normalisation, l'amélioration du contraste et l'équilibrage des classes, garantissant ainsi des conditions optimales d'apprentissage.

Les résultats obtenus avec le dataset CBIS-DDSM ont confirmé l'efficacité des CNN pour améliorer la précision et la fiabilité des diagnostics. L'analyse des performances via des métriques telles que la précision, le rappel et le score F1 a mis en évidence les forces et les limites de chaque modèle, soulignant leur potentiel dans le domaine médical.

Ce projet nous a permis de relever divers défis techniques liés à l'analyse d'images médicales et d'approfondir notre maîtrise des CNN et de leurs applications concrètes. Il ouvre des perspectives pour intégrer ces modèles dans des systèmes de diagnostic assisté par ordinateur, en soutien aux professionnels de santé.

À l'avenir, l'utilisation de modèles pré-entraînés sur des datasets médicaux diversifiés et le développement d'interfaces conviviales pour radiologues pourraient améliorer l'adoption de ces outils. Par ailleurs, l'exploration de solutions multimodales combinant images et données cliniques constitue une piste prometteuse.

En conclusion, ce projet a été une expérience enrichissante et formatrice, combinant innovation technologique et impact sociétal. Nous espérons que cette contribution aidera à améliorer le dépistage du cancer du sein, renforçant ainsi la lutte contre cette maladie et l'efficacité des soins aux patients.

# Bibliographie

- [1] Cours Mme Ibtissam ABNANE - Deep Learning.
- [2] <https://flask.palletsprojects.com/en/3.0.x/>
- [3] Cours Monsieur Radouane - Computer Vision.
- [4] <https://www.kaggle.com/>
- [5] <https://fritzing.org/>
- [6] VGG16 Pre-trained Model. <https://keras.io/api/applications/vgg/#vgg16-function>
- [7] VGG19 Pre-trained Model. <https://keras.io/api/applications/vgg/#vgg19-function>
- [8] DenseNet201 Pre-trained Model. <https://keras.io/api/applications/densenet/#densenet201-function>
- [9] CBIS-DDSM Breast Cancer Image Data-set. <https://www.kaggle.com/datasets/awsaf49/cbis-ddsm-breast-cancer-image-dataset/data>